UTS

PEMBELAJARAN MESIN



NAMA : Fauzan Mubarak.P

NIM : 202431146

KELAS : F

DOSEN : Dr. Dra. Dwina Kuswardani, M.Kom

NO.PC :

ASISTEN : 1. Jonathan Juan Setyanto

2. Muhammad Caisar Gemilang

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

DAFTAR ISI 2
BAB I 4
PENDAHULUAN 4
1.1 Rumusan Masalah 4
1.2 Tujuan Masalah 4
1.3 Manfaat Masalah 4
BAB II 5
LANDASAN TEORI 5
2.1 Pembelajaran Mesin (Machine Learning) 5
2.2 Dataset Bank Customers 5
2.3 Exploratory Data Analysis (EDA) 6
2.4 Preprocessing Data 6
2.5 Pembagian Data Training dan Testing 8
2.6 Algoritma Gaussian Naive Bayes 8
2.7 Algoritma Regresi Linear 9
2.8 Evaluasi Model Klasifikasi 9
2.9 Evaluasi Model Regresi 10
BAB III 12
HASIL 12
3.1 Persiapan dan Pembacaan Dataset 12
3.1.1 Import Library Python — Cell 1 12
3.1.2 Membaca Dataset Bank Customers — Cell 2 12
3.1.3 Pemeriksaan Struktur Dataset — Cell 3 13
3.2 Pemeriksaan Kualitas Data 14
3.2.1 Pemeriksaan Missing Values, Duplikat, dan Statistik Deskriptif — Cell 4 14
3.3 Exploratory Data Analysis (EDA) 16
3.3.1 Distribusi Keputusan Berlangganan Deposito — Cell 5 16
3.3.2 Distribusi Usia Nasabah — Cell 6 16
3.3.3 Distribusi Saldo Rekening Nasabah — Cell 7 17
3.4 Implementasi Gaussian Naive Bayes 18
3.4.1 Menentukan Fitur dan Target Klasifikasi — Cell 8 18

3.4.2 Pembagian Data Training dan Testing — Cell 9 18
3.4.3 Preprocessing Data Naive Bayes — Cell 10 19
3.4.4 Training Model Gaussian Naive Bayes — Cell 11 19
3.4.5 Prediksi Data Testing — Cell 12 20
3.4.6 Evaluasi Model Gaussian Naive Bayes — Cell 13 20
3.4.7 Confusion Matrix Gaussian Naive Bayes — Cell 14 21
3.5 Implementasi Regresi Linear 22
3.5.1 Menentukan Fitur dan Target Regresi Linear — Cell 15 22
3.5.2 Pembagian Data Training dan Testing — Cell 16 22
3.5.3 Preprocessing Regresi Linear — Cell 17 23
3.5.4 Training Model Regresi Linear — Cell 18 23
3.5.5 Prediksi Saldo Rekening Nasabah — Cell 19 24
3.5.6 Evaluasi Model Regresi Linear — Cell 20 24
3.5.7 Visualisasi Saldo Aktual dan Prediksi — Cell 21 25
3.5.8 Analisis Residual Regresi Linear — Cell 22 26
3.6 Rekapitulasi Hasil Praktikum 27
3.6.1 Rekap Hasil Evaluasi Kedua Algoritma — Cell 23 27
BAB IV 28
PENUTUP 28
DAFTAR PUSTAKA 29

BAB I

PENDAHULUAN

1.1 Rumusan Masalah

1. Bagaimana karakteristik dan kualitas data Bank Customers yang digunakan dalam praktikum pembelajaran mesin?
2. Bagaimana penerapan EDA, preprocessing, dan pembagian data untuk pembentukan model?
3. Bagaimana hasil klasifikasi deposito menggunakan Gaussian Naive Bayes, dan bagaimana hasil prediksi saldo menggunakan Regresi Linear?
4. Apa keterbatasan model yang diketahui dari metrik evaluasi dan grafik hasil?

1.2 Tujuan Masalah

1. Mengetahui struktur, karakteristik, distribusi, dan kualitas dataset Bank Customers.
2. Melaksanakan Exploratory Data Analysis untuk mengidentifikasi pola data, distribusi variabel, dan keberadaan nilai ekstrem.
3. Melaksanakan preprocessing data melalui pemisahan fitur dan target, penanganan nilai kosong, standardisasi, serta pengubahan variabel kategorikal menjadi bentuk numerik.
4. Mengimplementasikan Gaussian Naive Bayes untuk memprediksi keputusan nasabah berlangganan deposito berdasarkan atribut yang tersedia.
5. Mengimplementasikan Regresi Linear untuk memprediksi saldo rekening nasabah menggunakan variabel-variabel prediktor.
6. Mengevaluasi model Gaussian Naive Bayes menggunakan accuracy, precision, recall, F1-score, dan confusion matrix.

1.3Manfaat Masalah

- Pelaksanaan praktikum UTS ini memberikan manfaat dalam meningkatkan pemahaman dan keterampilan penerapan pembelajaran mesin pada data nyata.
- Bagi mahasiswa, praktikum ini memberikan pengalaman dalam mempersiapkan dataset, melakukan eksplorasi, menerapkan preprocessing, membangun model prediksi, dan mengevaluasi hasil menggunakan Python. Praktikum juga melatih kemampuan membaca grafik, memahami metrik evaluasi, dan menghubungkan hasil pengolahan data dengan teori pembelajaran mesin.
- Dari sisi penerapan, klasifikasi keputusan berlangganan deposito dapat memberikan gambaran mengenai kemungkinan pemanfaatan machine learning untuk mendukung kegiatan pemasaran perbankan. Sementara itu, pemodelan saldo rekening menggunakan Regresi Linear memberikan pengalaman dalam memahami hubungan variabel prediktor terhadap target numerik.
- Manfaat lainnya adalah memberikan pemahaman bahwa keberhasilan proses training tidak selalu berarti model mempunyai kemampuan prediksi yang tinggi. Hasil pengujian perlu ditafsirkan secara kritis melalui metrik evaluasi, distribusi data, dan karakteristik permasalahan yang dianalisis.

BAB II

LANDASAN TEORI

2.1 Pembelajaran Mesin (Machine Learning)

Pembelajaran mesin atau machine learning merupakan bidang kecerdasan buatan yang mempelajari bagaimana sistem komputer dapat mengenali pola dari data untuk menghasilkan prediksi atau keputusan. Proses pembelajaran dilakukan dengan menggunakan data sebagai dasar pembentukan model, sehingga sistem mampu melakukan generalisasi terhadap data yang belum pernah digunakan selama pelatihan.

Dalam penerapannya, machine learning memiliki beberapa pendekatan, salah satunya supervised learning atau pembelajaran terawasi. Pada pendekatan ini, algoritma dilatih menggunakan data yang mempunyai variabel masukan dan target yang telah diketahui. Model mempelajari hubungan antara variabel tersebut agar dapat menghasilkan prediksi terhadap data baru.

Supervised learning dapat dibedakan menjadi klasifikasi dan regresi. Klasifikasi digunakan untuk memprediksi kategori atau kelas, sedangkan regresi digunakan untuk memprediksi nilai numerik. Kedua pendekatan tersebut memiliki karakteristik dan metrik evaluasi yang berbeda.

Pada sektor perbankan, pembelajaran mesin dapat digunakan untuk menganalisis data nasabah dan membantu memperkirakan keputusan pelanggan terhadap produk deposito. Watono et al. (2024) menjelaskan bahwa klasifikasi penerimaan deposito merupakan permasalahan yang penting dalam pengembangan strategi pemasaran perbankan, terutama ketika data yang digunakan memiliki distribusi kelas tidak seimbang.

Dalam praktikum ini, supervised learning diterapkan melalui dua algoritma, yaitu Gaussian Naive Bayes untuk klasifikasi keputusan berlangganan deposito dan Regresi Linear untuk prediksi saldo rekening nasabah.

2.2 Dataset Bank Customers

Dataset merupakan kumpulan data terstruktur yang menjadi sumber informasi dalam proses pembelajaran mesin. Kualitas dan karakteristik dataset berpengaruh terhadap proses pelatihan, pengujian, dan interpretasi hasil model.

Dataset Bank Customers yang digunakan pada praktikum ini terdiri atas 45.211 baris data dan 17 kolom variabel. Data tersebut mencakup karakteristik demografis nasabah, kondisi keuangan, informasi pinjaman, serta riwayat interaksi pemasaran bank.

Variabel dalam dataset antara lain age, job, marital, education, default, balance, housing, loan, contact, day, month, duration, campaign, pdays, previous, poutcome, dan y.

Variabel age menunjukkan usia nasabah, job menunjukkan jenis pekerjaan, marital menunjukkan status perkawinan, education menunjukkan tingkat pendidikan, sedangkan balance menunjukkan saldo rekening. Variabel housing dan loan berkaitan dengan status pinjaman, sementara campaign, pdays, previous, dan poutcome berkaitan dengan riwayat kontak pemasaran.

Variabel y merupakan variabel kategorikal yang menunjukkan apakah nasabah berlangganan deposito, dengan dua kategori yaitu yes dan no.

Penelitian mengenai prediksi berlangganan deposito menggunakan machine learning juga dilakukan oleh Izma dan Firmansyah (2026). Penelitian tersebut menunjukkan bahwa penggunaan data nasabah untuk klasifikasi keputusan berlangganan deposito memiliki tantangan, khususnya pada pengenalan kelas pelanggan yang benar-benar berlangganan.

Dalam praktikum ini, dataset yang sama digunakan pada dua eksperimen dengan target berbeda. Gaussian Naive Bayes menggunakan y sebagai target klasifikasi, sedangkan Regresi Linear menggunakan balance sebagai target numerik. Perbedaan tersebut diperlukan karena kedua algoritma memiliki tujuan prediksi yang berbeda.

2.3 Exploratory Data Analysis (EDA)

Exploratory Data Analysis merupakan proses pemeriksaan dan eksplorasi data untuk memperoleh pemahaman awal mengenai struktur, karakteristik, distribusi, serta kemungkinan permasalahan dalam dataset.

EDA dilakukan sebelum proses pemodelan agar peneliti dapat mengenali kondisi data yang akan digunakan. Tahapan ini mencakup pemeriksaan jumlah baris dan kolom, jenis data, missing values, data duplikat, statistik deskriptif, dan visualisasi.

Statistik deskriptif digunakan untuk mengetahui karakteristik numerik, seperti nilai rata-rata, median, standar deviasi, nilai minimum, maksimum, dan kuartil. Informasi tersebut dapat membantu mengidentifikasi distribusi data yang tidak simetris maupun keberadaan nilai ekstrem.

Visualisasi merupakan bagian penting dari EDA. Grafik batang dapat digunakan untuk membandingkan jumlah observasi pada setiap kategori, histogram untuk memperlihatkan distribusi variabel numerik, dan boxplot untuk mengidentifikasi rentang sebaran serta kemungkinan outlier.

Dalam dataset Bank Customers, EDA digunakan untuk mengetahui proporsi nasabah yang berlangganan deposito, distribusi usia, dan variasi saldo rekening.

EDA juga berperan dalam mendukung keputusan preprocessing. Mujahid et al. (2024) menjelaskan pentingnya penyiapan dan pemeriksaan data sebelum digunakan dalam model machine learning, karena kualitas masukan memengaruhi kemampuan model mengenali pola yang relevan.

2.4 Preprocessing Data

Preprocessing data merupakan proses mempersiapkan data mentah agar dapat diproses secara tepat oleh algoritma pembelajaran mesin. Tahapan ini diperlukan karena dataset dapat memiliki nilai kosong, data kategorikal, perbedaan skala numerik, maupun distribusi yang tidak seimbang.

Mujahid et al. (2024) membahas pentingnya preprocessing dalam pengembangan model machine learning, terutama ketika data mempunyai karakteristik yang dapat memengaruhi proses pembelajaran.

Beberapa teknik preprocessing yang relevan dalam praktikum ini meliputi penanganan missing values, encoding variabel kategorikal, standardisasi fitur, dan pemisahan fitur dari target.

a. Penanganan Missing Values

Missing values merupakan kondisi ketika suatu atribut tidak memiliki nilai yang tersedia. Penanganannya dapat dilakukan dengan menghapus data tertentu atau mengganti nilai kosong menggunakan strategi imputasi, seperti median pada variabel numerik.

Dataset praktikum tidak memiliki missing values yang terdeteksi sebagai NaN. Namun, beberapa variabel kategorikal memiliki kategori unknown yang perlu dibedakan dari nilai kosong.

Kategori unknown tidak otomatis dihapus karena dapat menjadi kategori yang menggambarkan informasi tidak diketahui dalam pencatatan bank.

b. One-Hot Encoding

One-Hot Encoding merupakan teknik untuk mengubah nilai kategorikal menjadi representasi numerik berbentuk indikator biner. Teknik ini memungkinkan algoritma mengolah informasi kategori tanpa mengasumsikan hubungan urutan antarlabel.

Pada praktikum ini, One-Hot Encoding digunakan untuk variabel seperti job, marital, education, contact, dan sejumlah variabel kategorikal lainnya.

c. Standardisasi Data

Standardisasi merupakan proses transformasi fitur numerik agar memiliki skala yang lebih seragam. Salah satu metode yang umum digunakan adalah StandardScaler.

Secara matematis, standardisasi dapat dinyatakan sebagai berikut:

$z = (x - \mu) / \sigma$

Keterangan:

z = nilai setelah standardisasi

x = nilai asli suatu data

μ = rata-rata fitur pada data pelatihan

σ = standar deviasi fitur pada data pelatihan

Standardisasi membantu mengendalikan perbedaan skala antarfitur numerik, meskipun dampaknya dapat berbeda tergantung jenis algoritma.

d. Pipeline dan Pencegahan Data Leakage

Pipeline merupakan rangkaian proses pengolahan data dan pemodelan yang dijalankan secara berurutan. Dengan pipeline, transformasi data dapat dipelajari menggunakan data training dan kemudian diterapkan secara konsisten pada data testing.

Pendekatan ini juga membantu mencegah data leakage, yaitu kondisi ketika informasi dari data testing memengaruhi proses pelatihan model.

Pada praktikum ini, preprocessing dan algoritma digabungkan menggunakan Pipeline serta ColumnTransformer.

2.5 Pembagian Data Training dan Testing

Pembagian data training dan testing dilakukan untuk menilai kemampuan model ketika menerima data yang tidak digunakan dalam proses pelatihan.

Data training digunakan untuk mempelajari pola dan hubungan antarvariabel, sedangkan data testing digunakan untuk mengevaluasi hasil prediksi.

Dalam praktikum ini digunakan pembagian 80% untuk training dan 20% untuk testing. Dari 45.211 observasi, sebanyak 36.168 data digunakan untuk training dan 9.043 data digunakan untuk testing.

Pada model Naive Bayes, pembagian dilakukan menggunakan stratified sampling agar proporsi kelas yes dan no tetap terjaga pada kedua bagian data.

Pendekatan stratifikasi relevan ketika data mempunyai distribusi kelas tidak seimbang. Vargas et al. (2023) mengkaji berbagai pendekatan preprocessing untuk data tidak seimbang dan menunjukkan pentingnya memperhatikan distribusi kelas dalam penerapan machine learning.

Parameter random_state digunakan agar proses pembagian data dapat menghasilkan pembagian yang konsisten ketika eksperimen dijalankan ulang.

2.6Algoritma Gaussian Naive Bayes

Naive Bayes merupakan algoritma klasifikasi probabilistik yang didasarkan pada Teorema Bayes. Algoritma ini memperkirakan peluang suatu observasi termasuk ke dalam kelas tertentu berdasarkan nilai fitur yang dimilikinya.

Teorema Bayes dinyatakan melalui persamaan:

$P(C|X) = P(X|C) \times P(C) / P(X)$

Keterangan:

$P(C|X)$ = probabilitas kelas C berdasarkan fitur X

$P(X|C)$ = probabilitas fitur X ketika kelas C diketahui

$P(C)$ = probabilitas awal suatu kelas

$P(X)$ = probabilitas kemunculan fitur X

Algoritma Naive Bayes menggunakan asumsi bahwa fitur-fitur bersifat independen secara kondisional setelah kelas diketahui. Asumsi tersebut menyederhanakan proses perhitungan probabilitas, walaupun hubungan antarfitur dalam data nyata tidak selalu memenuhi independensi tersebut.

Gaussian Naive Bayes merupakan salah satu varian Naive Bayes yang menggunakan asumsi distribusi Gaussian untuk fitur numerik di dalam masing-masing kelas.

Dalam praktikum ini, Gaussian Naive Bayes digunakan untuk mengklasifikasikan keputusan nasabah berlangganan deposito. Variabel target y dikonversi menjadi label numerik, yaitu 0 untuk no dan 1 untuk yes.

Izma dan Firmansyah (2026) menerapkan Naive Bayes pada permasalahan prediksi keputusan berlangganan deposito. Penelitian tersebut memperlihatkan bahwa ketidakseimbangan kelas dapat menjadi tantangan dalam mendeteksi kelompok nasabah yang benar-benar berlangganan.

2.7 Algoritma Regresi Linear

Regresi Linear merupakan algoritma supervised learning yang digunakan untuk memprediksi nilai numerik berdasarkan hubungan antara satu atau beberapa variabel independen dengan variabel dependen.

Model Regresi Linear berganda dapat dituliskan sebagai berikut:

$\hat{y} = \beta_o + \beta_1 X_1 + \beta_2 X_2 + ... + \beta_n X_n$

Keterangan:

$\hat{y}$ = nilai target yang diprediksi

β_o = intercept atau konstanta

β_1 hingga β_n = koefisien regresi

X_1 hingga X_n = variabel prediktor

Regresi Linear mempelajari koefisien yang meminimalkan kesalahan kuadrat antara nilai prediksi dan nilai aktual.

Dalam praktikum ini, Regresi Linear digunakan untuk memprediksi saldo rekening nasabah berdasarkan atribut seperti usia, pekerjaan, pendidikan, dan variabel lainnya.

Pemilihan balance sebagai target numerik berbeda dari pemilihan y pada model klasifikasi. Oleh karena itu, hasil kedua eksperimen tidak dapat dibandingkan langsung menggunakan satu ukuran performa yang sama.

Model Regresi Linear mempunyai keterbatasan ketika hubungan antarvariabel tidak dapat direpresentasikan secara memadai menggunakan hubungan linear atau ketika nilai target memiliki penyebaran yang sangat ekstrem.

Müller-Plath dan Lüdecke (2024) membahas penggunaan ukuran kesalahan prediksi dan koefisien determinasi dalam menilai kesesuaian prediksi numerik terhadap data observasi.

2.8 Evaluasi Model Klasifikasi

Evaluasi klasifikasi bertujuan untuk mengukur kemampuan model dalam memprediksi kelas yang benar. Beberapa metrik yang digunakan meliputi accuracy, precision, recall, F1-score, dan confusion matrix.

Accuracy merupakan proporsi seluruh prediksi yang benar terhadap total data yang diuji.

Accuracy = (TP + TN) / (TP + TN + FP + FN)

Precision mengukur proporsi prediksi positif yang benar.

Precision = TP / (TP + FP)

Recall mengukur proporsi data positif sebenarnya yang berhasil dikenali.

Recall = TP / (TP + FN)

F1-score merupakan rata-rata harmonik antara precision dan recall.

F1-score = 2 × (Precision × Recall) / (Precision + Recall)

Confusion matrix menyajikan hubungan antara kelas aktual dan kelas hasil prediksi melalui empat komponen, yaitu True Positive, True Negative, False Positive, dan False Negative.

Pada dataset dengan kelas tidak seimbang, accuracy tidak selalu cukup untuk menggambarkan kemampuan model. Sebuah model dapat menghasilkan accuracy tinggi dengan lebih sering memprediksi kelas mayoritas.

Watono et al. (2024) dan Vargas et al. (2023) menunjukkan pentingnya memperhatikan ketidakseimbangan kelas dalam pengembangan dan evaluasi model klasifikasi.

Oleh karena itu, praktikum ini tidak hanya menggunakan accuracy, tetapi juga precision, recall, F1-score, dan confusion matrix untuk menilai kemampuan Gaussian Naive Bayes pada kelas yes.

2.9 Evaluasi Model Regresi

Evaluasi regresi dilakukan dengan membandingkan nilai numerik hasil prediksi dan nilai aktual. Beberapa metrik yang digunakan meliputi Mean Absolute Error, Mean Squared Error, Root Mean Squared Error, dan koefisien determinasi.

a. Mean Absolute Error (MAE)

MAE merupakan rata-rata selisih absolut antara nilai aktual dan prediksi.

$MAE = (1/n) \times \Sigma|y_i - \hat{y}_i|$

Semakin kecil nilai MAE, semakin kecil rata-rata kesalahan absolut model.

b. Mean Squared Error (MSE)

MSE merupakan rata-rata kuadrat selisih antara nilai aktual dan prediksi.

$MSE = (1/n) \times \Sigma(y_i - \hat{y}_i)^2$

MSE memberikan penalti yang lebih besar terhadap kesalahan prediksi yang ekstrem.

c. Root Mean Squared Error (RMSE)

RMSE merupakan akar kuadrat dari MSE.

$RMSE = \sqrt{MSE}$

RMSE memiliki satuan yang sama dengan variabel target sehingga lebih mudah diinterpretasikan dibandingkan MSE.

d. Koefisien Determinasi (R^2)

Koefisien determinasi digunakan untuk mengukur seberapa baik model menjelaskan variasi nilai target dibandingkan prediksi konstan berdasarkan rata-rata target.

$R^2 = 1 - [\Sigma(y_i - \hat{y}_i)^2 / \Sigma(y_i - \bar{y})^2]$

Nilai R^2 yang mendekati 1 menunjukkan kesesuaian model yang semakin baik, sedangkan nilai yang mendekati 0 menunjukkan kemampuan penjelasan variasi target yang terbatas. Nilai R^2 juga dapat negatif apabila model lebih buruk daripada baseline rata-rata.

e. Residual

Residual merupakan selisih antara nilai aktual dan nilai prediksi:

$e_i = y_i - \hat{y}_i$

Analisis residual digunakan untuk memeriksa pola kesalahan prediksi, termasuk ketidaksimetrisan distribusi dan keberadaan nilai ekstrem.

Müller-Plath dan Lüdecke (2024) membahas MAE, MSE, RMSE, serta R^2 sebagai ukuran yang digunakan untuk mengevaluasi kesesuaian nilai prediksi numerik terhadap hasil pengamatan.

BAB III

HASIL

3.1Persiapan dan Pembacaan Dataset

Praktikum UTS Pembelajaran Mesin dilaksanakan menggunakan aplikasi Jupyter Notebook dengan bahasa pemrograman Python. Dataset yang digunakan adalah Bank Customers dengan nama file 04_bank_customers.csv.

Seluruh proses analisis dilakukan secara bertahap, mulai dari membaca dataset, memeriksa kualitas data, melakukan Exploratory Data Analysis (EDA), preprocessing, training model, prediksi, hingga evaluasi hasil.

3.1.1 Import Library Python — Cell 1

Tahap pertama adalah melakukan import library Python yang diperlukan untuk pengolahan data, analisis numerik, dan visualisasi.

Library pandas digunakan untuk membaca dan memanipulasi dataset dalam bentuk DataFrame. NumPy digunakan untuk operasi numerik. Matplotlib dan Seaborn digunakan untuk membuat visualisasi yang mempermudah analisis data.

Pada cell pertama, seluruh library berhasil diimpor tanpa menghasilkan pesan kesalahan.

Hasil output:

Semua library berhasil diimport!

Hasil tersebut menunjukkan bahwa lingkungan Jupyter Notebook telah siap digunakan untuk tahapan analisis berikutnya.

[1]:
```
# NIM: 202431146
# Nama: Fauzan Mubarak P
# Project UTS Pembelajaran Mesin

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

print("Semua library berhasil diimport!")
```

```
Semua library berhasil diimport!
```

3.1.2 Membaca Dataset Bank Customers — Cell 2

Dataset dibaca menggunakan fungsi read_csv() dari library pandas. Dalam proses ini digunakan parameter sep=";" karena file CSV memiliki karakter titik koma sebagai pemisah antarkolom.

Data yang berhasil dibaca disimpan dalam variabel df. Selanjutnya digunakan perintah df.shape untuk mengetahui dimensi dataset dan df.head() untuk menampilkan lima observasi pertama.

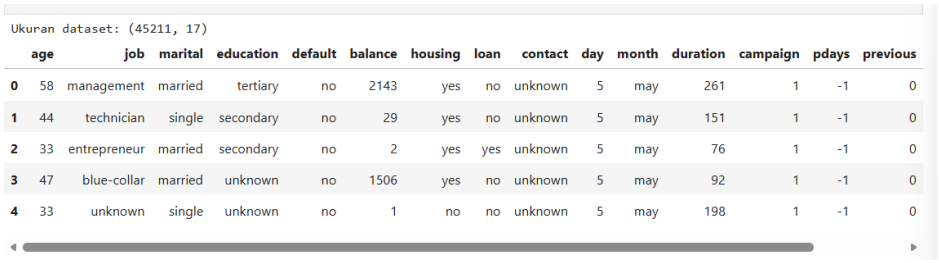
Hasil output:

Ukuran dataset: (45211, 17)

Hasil tersebut menunjukkan bahwa dataset terdiri atas 45.211 baris dan 17 kolom.

Lima observasi pertama memperlihatkan beberapa variabel, seperti age, job, marital, education, balance, housing, loan, dan y. Data tersebut menggambarkan karakteristik nasabah dan informasi yang berkaitan dengan aktivitas pemasaran deposito bank.

Keberhasilan proses pembacaan dataset menjadi dasar untuk melaksanakan pemeriksaan dan analisis data pada tahap berikutnya.



```
Ukuran dataset: (45211, 17)
```

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous
0	58	management	married	tertiary	no	2143	yes	no	unknown	5	may	261	1	-1	0
1	44	technician	single	secondary	no	29	yes	no	unknown	5	may	151	1	-1	0
2	33	entrepreneur	married	secondary	no	2	yes	yes	unknown	5	may	76	1	-1	0
3	47	blue-collar	married	unknown	no	1506	yes	no	unknown	5	may	92	1	-1	0
4	33	unknown	single	unknown	no	1	no	no	unknown	5	may	198	1	-1	0

3.1.3 Pemeriksaan Struktur Dataset — Cell 3

Pemeriksaan struktur data dilakukan menggunakan fungsi df.info(). Fungsi tersebut menampilkan jumlah observasi, nama kolom, jenis data, serta jumlah nilai yang tersedia dalam setiap kolom.

Berdasarkan hasil pemeriksaan, diketahui bahwa dataset memiliki tujuh kolom numerik dengan tipe int64 dan sepuluh kolom kategorikal dengan tipe string.

Variabel numerik meliputi age, balance, day, duration, campaign, pdays, dan previous. Sementara itu, variabel kategorikal meliputi job, marital, education, default, housing, loan, contact, month, poutcome, dan y.

Seluruh kolom mempunyai 45.211 nilai non-null.

Hasil output:

Jumlah baris: 45211

Jumlah kolom: 17

Tipe numerik: 7 kolom

Tipe kategorikal: 10 kolom

Hasil tersebut menunjukkan bahwa dataset memiliki dua kelompok tipe data yang membutuhkan perlakuan berbeda pada proses preprocessing, terutama karena algoritma pembelajaran mesin yang digunakan membutuhkan representasi fitur numerik.

```
<class 'pandas.DataFrame'>
RangeIndex: 45211 entries, 0 to 45210
Data columns (total 17 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   age        45211 non-null  int64
 1   job        45211 non-null  str
 2   marital    45211 non-null  str
 3   education  45211 non-null  str
 4   default    45211 non-null  str
 5   balance    45211 non-null  int64
 6   housing    45211 non-null  str
 7   loan       45211 non-null  str
 8   contact    45211 non-null  str
 9   day        45211 non-null  int64
 10  month      45211 non-null  str
 11  duration   45211 non-null  int64
 12  campaign   45211 non-null  int64
 13  pdays      45211 non-null  int64
 14  previous   45211 non-null  int64
 15  poutcome   45211 non-null  str
 16  y          45211 non-null  str
dtypes: int64(7), str(10)
memory usage: 8.1 MB

Jumlah baris: 45211
Jumlah kolom: 17
```

3.2Pemeriksaan Kualitas Data

3.2.1 Pemeriksaan Missing Values, Duplikat, dan Statistik Deskriptif — Cell 4

Tahap pemeriksaan kualitas data dilakukan untuk mengetahui kondisi dataset sebelum digunakan dalam proses pembelajaran mesin.

Pemeriksaan missing values dilakukan menggunakan fungsi isnull().sum(), sedangkan data duplikat diperiksa menggunakan fungsi duplicated().sum().

Selain itu, dilakukan pemeriksaan terhadap kategori unknown pada variabel kategorikal dan analisis statistik deskriptif menggunakan fungsi describe().

Berdasarkan output yang diperoleh, tidak ditemukan missing values yang terdeteksi sebagai NaN pada seluruh kolom. Jumlah baris duplikat juga menunjukkan angka nol.

Namun, beberapa atribut kategorikal memiliki nilai unknown, yaitu:

Variabel	**Jumlah Unknown**
job	288
education	1.857
contact	13.020
poutcome	36.959

Nilai unknown menunjukkan bahwa terdapat informasi kategori yang tidak diketahui dalam dataset. Nilai tersebut tidak otomatis dihapus karena dapat merepresentasikan kondisi pencatatan data, bukan selalu kesalahan input.

Pemeriksaan statistik deskriptif menunjukkan beberapa karakteristik penting dari variabel numerik.

Statistik	**age**	**balance**
Rata-rata	40,94	1.362,27
Median	39	448
Minimum	18	-8.019
Maksimum	95	102.127
Standar deviasi	10,62	3.044,77

Berdasarkan tabel tersebut, rata-rata usia nasabah adalah sekitar 40,94 tahun. Usia termuda adalah 18 tahun dan usia tertua adalah 95 tahun.

Pada variabel balance, nilai rata-rata lebih besar dibandingkan median. Kondisi ini menunjukkan bahwa distribusi saldo cenderung tidak simetris dan dipengaruhi oleh sejumlah nilai saldo yang jauh lebih tinggi dibandingkan mayoritas data.

Terdapat pula saldo bernilai negatif. Nilai tersebut tidak langsung dinyatakan sebagai data salah karena saldo negatif dapat berkaitan dengan kondisi rekening tertentu.

Secara keseluruhan, dataset tidak memerlukan penghapusan baris akibat missing values atau duplikasi. Meskipun demikian, variasi data kategorikal dan nilai ekstrem tetap perlu diperhatikan dalam proses analisis dan pemodelan.

```
=== MISSING VALUES ===
age          0
job          0
marital      0
education    0
default      0
balance      0
housing      0
loan         0
contact      0
day          0
month        0
duration     0
campaign     0
pdays        0
previous     0
poutcome     0
y            0
dtype: int64

=== DATA DUPLIKAT ===
Jumlah duplikat: 0

=== NILAI UNKNOWN ===
job: 288
marital: 0
education: 1857
default: 0
housing: 0
loan: 0
contact: 13020
month: 0
poutcome: 36959
y: 0

=== STATISTIK DESKRIPTIF ===
```

	age	balance	day	duration	campaign	pdays	previous
count	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000	45211.000000
mean	40.936210	1362.272058	15.806419	258.163080	2.763841	40.197828	0.580323
std	10.618762	3044.765829	8.322476	257.527812	3.098021	100.128746	2.303441
min	18.000000	-8019.000000	1.000000	0.000000	1.000000	-1.000000	0.000000
25%	33.000000	72.000000	8.000000	103.000000	1.000000	-1.000000	0.000000
50%	39.000000	448.000000	16.000000	180.000000	2.000000	-1.000000	0.000000
75%	48.000000	1428.000000	21.000000	319.000000	3.000000	-1.000000	0.000000
max	95.000000	102127.000000	31.000000	4918.000000	63.000000	871.000000	275.000000

3.3 Exploratory Data Analysis (EDA)

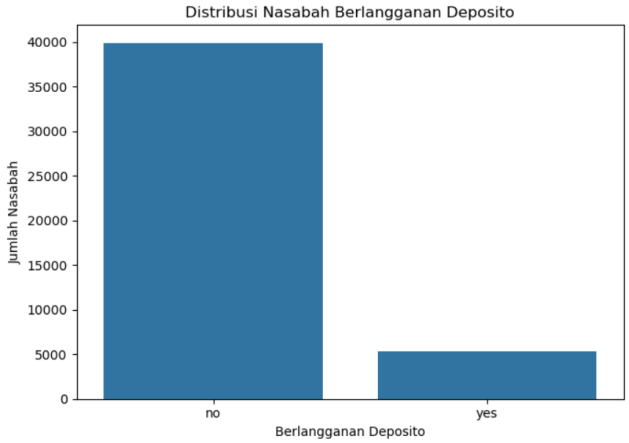
3.3.1 Distribusi Keputusan Berlangganan Deposito — Cell 5

Pada tahap ini dibuat grafik batang menggunakan fungsi countplot() dari library Seaborn untuk melihat distribusi variabel target y.

Variabel y terdiri atas dua kategori, yaitu no yang menunjukkan nasabah tidak berlangganan deposito dan yes yang menunjukkan nasabah berlangganan deposito.

Berdasarkan hasil perhitungan, diperoleh:

Kategori	Jumlah Nasabah	Persentase
Tidak (no)	39.922	88,30%
Ya (yes)	5.289	11,70%
Total	45.211	100%



Berdasarkan grafik, jumlah nasabah yang tidak berlangganan deposito jauh lebih banyak dibandingkan nasabah yang berlangganan.

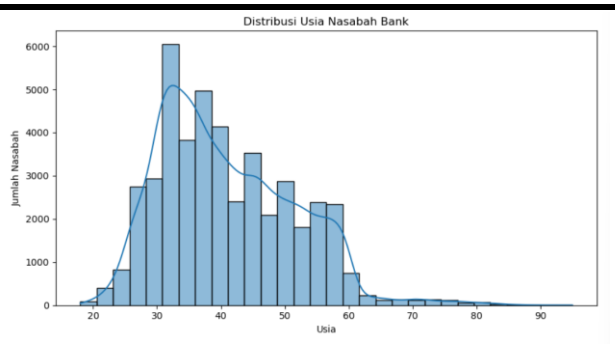
Distribusi tersebut menunjukkan adanya ketidakseimbangan kelas atau class imbalance, dengan kategori no sebagai kelas mayoritas dan kategori yes sebagai kelas minoritas.

Kondisi ini berpengaruh terhadap evaluasi model klasifikasi. Model yang menghasilkan accuracy tinggi belum tentu memiliki kemampuan yang baik dalam mengenali nasabah pada kelas minoritas.

Oleh karena itu, dalam evaluasi Gaussian Naive Bayes diperlukan metrik tambahan berupa precision, recall, dan F1-score.

3.3.2 Distribusi Usia Nasabah — Cell 6

Distribusi usia dianalisis menggunakan histogram dan kurva estimasi kepadatan (KDE). Visualisasi tersebut digunakan untuk mengetahui persebaran usia dan kelompok usia yang paling banyak terdapat dalam dataset.



Berdasarkan hasil visualisasi, sebagian besar nasabah berada pada kelompok usia dewasa, terutama dalam rentang sekitar 30 sampai 60 tahun.

Konsentrasi frekuensi tertinggi terlihat pada kelompok usia awal 30-an, sedangkan jumlah nasabah cenderung menurun pada kelompok usia yang lebih tinggi.

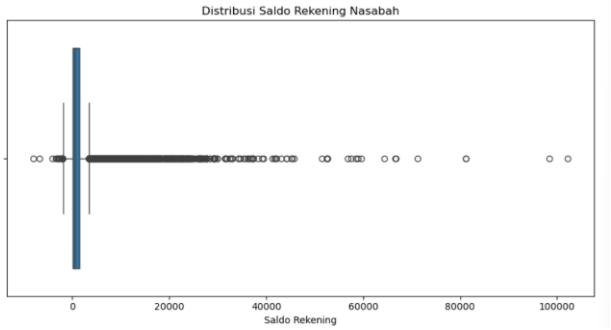
Hasil statistik deskriptif menunjukkan bahwa rata-rata usia nasabah adalah 40,94 tahun, dengan nilai minimum 18 tahun dan maksimum 95 tahun.

Distribusi usia mempunyai ekor ke kanan karena terdapat sejumlah kecil nasabah berusia lanjut. Hal ini menunjukkan bahwa persebaran usia tidak sepenuhnya simetris.

Informasi mengenai karakteristik usia dapat membantu memahami komposisi nasabah dalam dataset sebelum melakukan prediksi.

3.3.3 Distribusi Saldo Rekening Nasabah — Cell 7

Variabel balance dianalisis menggunakan boxplot untuk memperlihatkan median, rentang kuartil, serta keberadaan nilai ekstrem pada saldo rekening.



Berdasarkan grafik, sebagian besar saldo nasabah terkonsentrasi pada rentang nilai yang relatif rendah dibandingkan dengan keseluruhan rentang data.

Pada sisi kanan grafik terlihat banyak titik yang berada jauh dari kotak utama. Titik-titik tersebut menunjukkan keberadaan nilai ekstrem atau outlier positif.

Berdasarkan statistik deskriptif, saldo minimum adalah -8.019, median 448, rata-rata 1.362,27, dan maksimum 102.127.

Perbedaan yang cukup besar antara rata-rata dan median menunjukkan bahwa nilai saldo tinggi berpengaruh terhadap rata-rata keseluruhan. Distribusi saldo juga cenderung menceng ke kanan.

Keberadaan nilai ekstrem menjadi pertimbangan dalam pemodelan Regresi Linear karena model dengan fungsi kerugian kuadrat dapat terpengaruh oleh kesalahan prediksi yang besar.

Namun, pada praktikum ini outlier tidak dihapus secara otomatis karena nilai tersebut masih mungkin merepresentasikan saldo rekening yang valid.

3.4 Implementasi Gaussian Naive Bayes

3.4.1 Menentukan Fitur dan Target Klasifikasi — Cell 8

Tahap awal implementasi Gaussian Naive Bayes adalah menentukan variabel masukan (fitur) dan variabel keluaran (target).

Target yang digunakan adalah kolom y, yaitu keputusan nasabah dalam berlangganan deposito. Nilai kategori no diubah menjadi 0, sedangkan yes diubah menjadi 1.

Fitur diperoleh dari seluruh kolom dataset dengan mengecualikan variabel y dan duration.

Kolom duration tidak digunakan karena menunjukkan durasi kontak pemasaran yang baru diketahui setelah panggilan berlangsung. Penghapusan kolom tersebut dilakukan agar model dapat diarahkan pada skenario prediksi sebelum kontak berlangsung.

Hasil output:

```
Ukuran fitur: (45211, 15)
Ukuran target: (45211,)

Distribusi target:
y
0    39922
1     5289
Name: count, dtype: int64
```

Hasil tersebut menunjukkan bahwa terdapat 15 fitur yang digunakan untuk memprediksi satu variabel target klasifikasi.

3.4.2 Pembagian Data Training dan Testing — Cell 9

Dataset dibagi menggunakan fungsi train_test_split() dari library scikit-learn. Pembagian dilakukan dengan proporsi 80% untuk data training dan 20% untuk data testing.

Parameter random_state=42 digunakan untuk menjaga konsistensi hasil pembagian ketika program dijalankan ulang. Parameter stratify digunakan untuk mempertahankan distribusi kelas target pada data training dan testing.

Hasil output:

```
Data training: (36168, 15)
Data testing: (9043, 15)

Distribusi target training:
y
0    0.883018
1    0.116982
Name: proportion, dtype: float64

Distribusi target testing:
y
0    0.883003
1    0.116997
Name: proportion, dtype: float64
```

Hasil tersebut menunjukkan bahwa pembagian dataset berhasil dilakukan dengan proporsi kelas yang relatif sama pada kedua bagian.

Penerapan stratifikasi penting karena dataset mempunyai distribusi kelas tidak seimbang. Dengan demikian, data testing tetap memiliki representasi dari kelas mayoritas dan minoritas.

3.4.3 Preprocessing Data Naive Bayes — Cell 10

Pada tahap preprocessing digunakan ColumnTransformer dan Pipeline untuk mengatur proses pengolahan fitur numerik serta kategorikal.

Fitur numerik yang digunakan meliputi age, balance, day, campaign, pdays, dan previous.

Fitur kategorikal meliputi job, marital, education, default, housing, loan, contact, month, dan poutcome.

Pada fitur numerik digunakan SimpleImputer dengan strategi median dan StandardScaler. SimpleImputer disiapkan untuk menangani nilai kosong, sedangkan StandardScaler digunakan untuk menstandardisasi skala fitur numerik.

Pada fitur kategorikal digunakan OneHotEncoder untuk mengubah nilai kategori menjadi representasi angka. Parameter handle_unknown="ignore" digunakan agar proses transformasi dapat menangani kategori yang tidak muncul pada data training.

Seluruh preprocessing digabungkan menggunakan ColumnTransformer.

Hasil output:

```
Kolom numerik: ['age', 'balance', 'day', 'campaign', 'pdays', 'previous']
Kolom kategorikal: ['job', 'marital', 'education', 'default', 'housing', 'loan', 'contact', 'month', 'poutcome']

Preprocessing berhasil dibuat!
```

Hasil tersebut menunjukkan bahwa komponen preprocessing telah berhasil didefinisikan. Proses transformasi kemudian dijalankan saat pipeline model dilatih menggunakan data training.

3.4.4 Training Model Gaussian Naive Bayes — Cell 11

Model klasifikasi dibangun menggunakan GaussianNB() dari library scikit-learn.

Pada tahap ini dibuat sebuah Pipeline yang menggabungkan preprocessing dengan algoritma Gaussian Naive Bayes.

Model dilatih menggunakan fungsi fit() dengan data fitur training dan label target training yang sebelumnya telah dipisahkan.

Hasil output:

Training Gaussian Naive Bayes berhasil!

Output tersebut menunjukkan bahwa proses preprocessing dan pelatihan model telah berhasil dilaksanakan tanpa error.

Model yang telah dilatih kemudian digunakan untuk menghasilkan prediksi pada data testing.

3.4.5 Prediksi Data Testing — Cell 12

Setelah proses training selesai, model digunakan untuk melakukan prediksi terhadap data testing menggunakan fungsi predict().

Prediksi dilakukan untuk menentukan apakah setiap nasabah diperkirakan akan berlangganan deposito atau tidak.

Hasil prediksi dibandingkan dengan label aktual untuk mengetahui kesesuaian keluaran model.

```
Prediksi berhasil!

10 hasil prediksi pertama:
[0 0 0 0 0 0 0 1 0 0]

10 target aktual pertama:
[0 0 0 0 0 0 0 1 0 0]
```

Berdasarkan sepuluh observasi pertama, seluruh prediksi model sesuai dengan nilai aktual.

Namun, hasil tersebut belum dapat digunakan untuk menyimpulkan bahwa model mempunyai tingkat akurasi sempurna. Evaluasi harus dilakukan terhadap seluruh data testing, yaitu sebanyak 9.043 observasi.

3.4.6 Evaluasi Model Gaussian Naive Bayes — Cell 13

Evaluasi dilakukan menggunakan accuracy, precision, recall, F1-score, dan classification report. Penghitungan metrik dilakukan dengan membandingkan label aktual dengan hasil prediksi pada seluruh data testing.

Hasil evaluasi:

```
=== EVALUASI NAIVE BAYES ===
Accuracy  : 0.8452
Precision : 0.3708
Recall    : 0.4641
F1-Score  : 0.4123

=== CLASSIFICATION REPORT ===
              precision    recall  f1-score   support

       Tidak       0.93      0.90      0.91      7985
          Ya       0.37      0.46      0.41      1058

    accuracy                           0.85      9043
   macro avg       0.65      0.68      0.66      9043
weighted avg       0.86      0.85      0.85      9043
```

Berdasarkan hasil pengujian, Gaussian Naive Bayes menghasilkan accuracy sebesar 84,52%. Nilai tersebut menunjukkan bahwa sebagian besar prediksi pada keseluruhan data testing sudah sesuai dengan label aktual.

Meskipun demikian, precision pada kelas positif hanya mencapai 37,08%. Artinya, dari seluruh nasabah yang diprediksi akan berlangganan deposito, sekitar 37,08% benar-benar termasuk ke dalam kelas positif.

Recall kelas positif sebesar 46,41% menunjukkan bahwa model berhasil mengenali sekitar 46,41% nasabah yang benar-benar berlangganan deposito.

Nilai F1-score sebesar 41,23% menunjukkan bahwa keseimbangan antara precision dan recall kelas positif masih tergolong terbatas.

Hasil ini berkaitan dengan karakteristik dataset yang tidak seimbang, karena sebagian besar observasi termasuk ke dalam kelas no.

Sebagai pembanding, prediksi yang selalu memilih kelas mayoritas no akan menghasilkan accuracy sekitar 88,30% pada data testing. Oleh karena itu, accuracy model Naive Bayes sebesar 84,52% tidak dapat dianggap sebagai bukti bahwa model sudah optimal.

Namun, model Naive Bayes mempunyai kemampuan untuk mengenali sebagian kelas positif, sedangkan prediksi yang selalu memilih kelas no tidak dapat mendeteksi nasabah yang berlangganan.

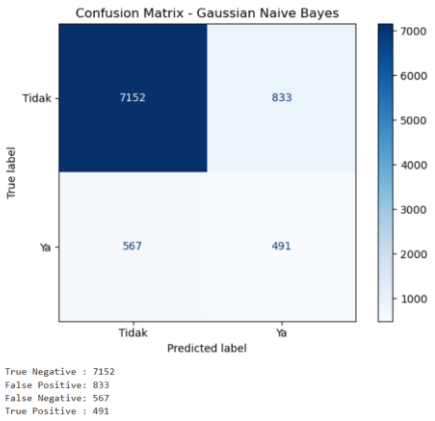
Secara keseluruhan, model Gaussian Naive Bayes telah berhasil diimplementasikan, tetapi kemampuan klasifikasi untuk kelas positif masih perlu ditingkatkan.

3.4.7 Confusion Matrix Gaussian Naive Bayes — Cell 14

Confusion matrix digunakan untuk memperlihatkan jumlah prediksi benar dan salah dari setiap kelas.

Visualisasi dibuat menggunakan ConfusionMatrixDisplay dari library scikit-learn.

Hasil confusion matrix:



Berdasarkan confusion matrix, terdapat 7.152 True Negative, yaitu nasabah yang benar-benar tidak berlangganan deposito dan berhasil diprediksi sebagai tidak berlangganan.

Terdapat 491 True Positive, yaitu nasabah yang benar-benar berlangganan deposito dan berhasil diprediksi dengan benar oleh model.

Sementara itu, terdapat 833 False Positive, yaitu nasabah yang tidak berlangganan tetapi diprediksi akan berlangganan.

Terdapat pula 567 False Negative, yaitu nasabah yang sebenarnya berlangganan tetapi diprediksi tidak berlangganan.

Secara keseluruhan, model menghasilkan 7.643 prediksi benar dan 1.400 prediksi salah dari 9.043 data testing.

Hasil confusion matrix memperlihatkan bahwa model lebih mampu mengenali kelas no dibandingkan kelas yes.

Hal tersebut konsisten dengan distribusi target yang tidak seimbang, serta nilai precision dan recall kelas positif yang masih relatif rendah.

Dengan demikian, model Gaussian Naive Bayes dapat digunakan sebagai model klasifikasi awal, tetapi hasilnya belum cukup kuat untuk dijadikan satu-satunya dasar dalam menentukan nasabah yang berpotensi berlangganan deposito.

3.5 Implementasi Regresi Linear

3.5.1 Menentukan Fitur dan Target Regresi Linear — Cell 15

Eksperimen kedua menggunakan algoritma Regresi Linear yang bertujuan untuk memprediksi nilai numerik.

Pada tahap ini, variabel balance digunakan sebagai target prediksi. Variabel tersebut menunjukkan saldo rekening nasabah.

Fitur prediktor diperoleh dari dataset dengan mengecualikan balance, y, dan duration.

Variabel balance tidak digunakan sebagai fitur karena merupakan target yang ingin diprediksi. Variabel y dikeluarkan karena menunjukkan keputusan berlangganan deposito, sedangkan duration dikeluarkan agar eksperimen difokuskan pada atribut nasabah dan informasi kampanye yang dipilih.

Hasil output:

```
=== REGRESI LINEAR ===
Jumlah fitur: 14
Jumlah data: 45211

Statistik target balance:
count     45211.000000
mean       1362.272058
std        3044.765829
min       -8019.000000
25%          72.000000
50%         448.000000
75%        1428.000000
max      102127.000000
Name: balance, dtype: float64
```

Hasil tersebut menunjukkan bahwa saldo nasabah memiliki variasi yang cukup besar, dengan selisih yang jauh antara nilai minimum dan maksimum.

Kondisi tersebut menjadi salah satu karakteristik penting dalam proses pemodelan Regresi Linear.

3.5.2 Pembagian Data Training dan Testing — Cell 16

Data Regresi Linear dibagi menggunakan fungsi train_test_split() dengan proporsi 80% data training dan 20% data testing.

Parameter random_state=42 digunakan untuk menghasilkan pembagian data yang konsisten saat program dijalankan kembali.

Hasil output:

```
Data training: (36168, 14)
Data testing: (9043, 14)
```

Hasil tersebut menunjukkan bahwa pembagian dataset berhasil dilakukan.

Data training digunakan untuk mempelajari hubungan fitur prediktor dengan saldo rekening, sedangkan data testing digunakan untuk mengevaluasi kemampuan prediksi model.

Berbeda dengan klasifikasi Naive Bayes, pembagian data Regresi Linear tidak menggunakan stratify karena target balance merupakan variabel numerik kontinu.

3.5.3 Preprocessing Regresi Linear — Cell 17

Tahap preprocessing dilakukan untuk menyiapkan fitur numerik dan kategorikal sebelum digunakan oleh algoritma Regresi Linear.

Fitur numerik yang digunakan terdiri atas age, day, campaign, pdays, dan previous.

Fitur kategorikal terdiri atas job, marital, education, default, housing, loan, contact, month, dan poutcome.

Pada fitur numerik digunakan SimpleImputer dengan strategi median serta StandardScaler untuk melakukan standardisasi.

Pada fitur kategorikal digunakan OneHotEncoder untuk mengubah kategori menjadi bentuk numerik yang dapat diproses oleh model Regresi Linear.

Seluruh proses tersebut digabungkan menggunakan ColumnTransformer dan kemudian digunakan dalam Pipeline pemodelan.

Hasil output:

```
Kolom numerik: ['age', 'day', 'campaign', 'pdays', 'previous']
Kolom kategorikal: ['job', 'marital', 'education', 'default', 'housing', 'loan', 'contact', 'month', 'poutcome']

Preprocessing Regresi Linear berhasil dibuat!
```

Hasil tersebut menunjukkan bahwa komponen preprocessing telah berhasil disiapkan dan dapat digunakan pada proses training.

3.5.4 Training Model Regresi Linear — Cell 18

Model Regresi Linear dibangun menggunakan kelas LinearRegression dari library scikit-learn.

Pada tahap ini dibuat sebuah Pipeline yang menggabungkan proses preprocessing dengan algoritma Regresi Linear.

Pelatihan dilakukan menggunakan fungsi fit() dengan data training yang sebelumnya telah dipisahkan.

Hasil output:

```
Training Regresi Linear berhasil!
```

Hasil tersebut menunjukkan bahwa model berhasil melalui proses pelatihan tanpa error.

Setelah pelatihan selesai, model dapat digunakan untuk memprediksi saldo rekening pada data testing.

3.5.5 Prediksi Saldo Rekening Nasabah — Cell 19

Tahap prediksi dilakukan menggunakan fungsi predict() dengan memasukkan fitur dari data testing.

Hasil prediksi kemudian dibandingkan dengan nilai saldo aktual menggunakan DataFrame yang memiliki dua kolom, yaitu Saldo Aktual dan Saldo Prediksi.

10 hasil prediksi pertama:

	Saldo Aktual	Saldo Prediksi
0	580	1027.375131
1	3644	1774.592316
2	538	1719.051868
3	1773	2073.175495
4	217	1497.108020
5	1134	913.084756
6	1085	899.117183
7	127	1726.597065
8	3	710.680842
9	258	1142.910587

Berdasarkan hasil tersebut, ditemukan perbedaan antara nilai saldo aktual dengan nilai saldo hasil prediksi.

Sebagai contoh, nasabah dengan saldo aktual sebesar 580 diprediksi memiliki saldo sebesar 1.027,38. Pada observasi lain, saldo aktual sebesar 3.644 diprediksi sebesar 1.774,59.

Perbedaan tersebut menunjukkan bahwa model belum dapat memperkirakan setiap nilai saldo dengan tepat.

Namun, evaluasi tidak dapat hanya didasarkan pada sepuluh observasi pertama. Oleh karena itu, pengujian dilanjutkan menggunakan metrik evaluasi regresi terhadap seluruh data testing.

3.5.6 Evaluasi Model Regresi Linear — Cell 20

Evaluasi Regresi Linear dilakukan menggunakan empat metrik, yaitu Mean Absolute Error, Mean Squared Error, Root Mean Squared Error, dan koefisien determinasi.

```
=== EVALUASI REGRESI LINEAR ===
MAE  : 1486.6445
MSE  : 9337688.8114
RMSE : 3055.7632
R2   : 0.0469
```

Nilai MAE sebesar 1.486,6445 menunjukkan bahwa rata-rata kesalahan absolut prediksi saldo mencapai sekitar 1.486,64 satuan saldo.

Nilai RMSE sebesar 3.055,7632 menunjukkan bahwa kesalahan prediksi yang besar memberikan pengaruh cukup kuat terhadap evaluasi, karena RMSE memberikan bobot lebih besar pada kesalahan ekstrem.

Hasil evaluasi juga menunjukkan nilai R^2 sebesar 0,0469 atau sekitar 4,69%.

Nilai tersebut menunjukkan bahwa model hanya mampu menjelaskan sekitar 4,69% variasi saldo pada data testing jika dibandingkan dengan baseline prediksi konstan menggunakan rata-rata target testing.

Dengan demikian, kemampuan model dalam memprediksi saldo rekening masih tergolong rendah.

Hasil ini menunjukkan bahwa hubungan antara saldo rekening dengan fitur-fitur yang digunakan belum dapat direpresentasikan dengan baik oleh model linear yang dibangun.

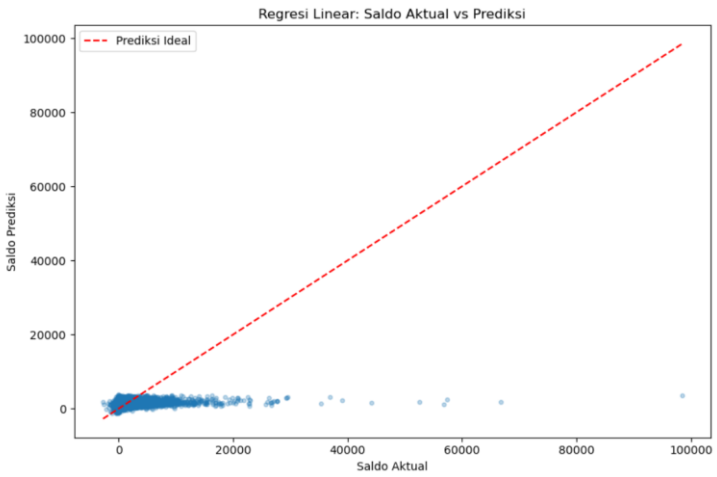
Kondisi tersebut dapat berkaitan dengan distribusi saldo yang sangat tidak simetris, keberadaan nilai ekstrem, serta kemungkinan bahwa hubungan antarvariabel lebih kompleks daripada hubungan linear sederhana.

3.5.7 Visualisasi Saldo Aktual dan Prediksi — Cell 21

Untuk memperjelas hasil prediksi, dibuat grafik scatter plot yang membandingkan saldo aktual dengan saldo hasil prediksi.

Sumbu horizontal menunjukkan nilai saldo aktual, sedangkan sumbu vertikal menunjukkan nilai saldo prediksi.

Garis diagonal merah putus-putus digunakan sebagai garis prediksi ideal. Apabila hasil prediksi sama dengan nilai aktual, titik akan berada pada garis tersebut.



Berdasarkan grafik, sebagian besar titik prediksi berada pada rentang nilai yang relatif rendah meskipun saldo aktual memiliki rentang yang jauh lebih besar.

Pada observasi dengan saldo aktual tinggi, model cenderung menghasilkan prediksi jauh di bawah nilai aktual.

Kondisi tersebut menunjukkan adanya underprediction, khususnya pada nasabah dengan saldo rekening yang sangat tinggi.

Selain itu, banyak titik berada jauh dari garis prediksi ideal sehingga menunjukkan bahwa kesalahan prediksi masih cukup besar.

Hasil visualisasi ini sejalan dengan nilai RMSE yang tinggi dan koefisien determinasi R^2 yang rendah.

Dengan demikian, grafik memperkuat kesimpulan bahwa model Regresi Linear yang digunakan belum mampu memprediksi variasi saldo rekening secara optimal.

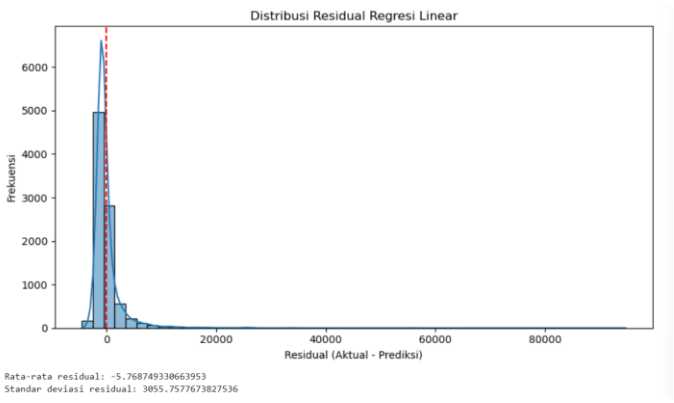
3.5.8 Analisis Residual Regresi Linear — Cell 22

Residual merupakan selisih antara nilai saldo aktual dan saldo hasil prediksi.

Analisis residual dilakukan untuk mengetahui karakteristik kesalahan prediksi model Regresi Linear.

Pada praktikum ini, residual dihitung dengan mengurangkan nilai prediksi dari nilai aktual, kemudian divisualisasikan menggunakan histogram dan kurva kepadatan.

Hasil output:



Berdasarkan grafik residual, terlihat bahwa sebagian besar kesalahan prediksi terkonsentrasi pada rentang nilai tertentu di sekitar nol, tetapi distribusinya memiliki ekor panjang ke arah positif.

Hal tersebut menunjukkan bahwa pada sejumlah observasi, nilai saldo aktual jauh lebih tinggi daripada nilai saldo yang diprediksi.

Rata-rata residual sebesar -5,7687 menunjukkan bahwa rata-rata kesalahan bertanda relatif mendekati nol. Namun, kondisi ini tidak dapat langsung diartikan bahwa seluruh prediksi sudah akurat, karena residual positif dan negatif dapat saling meniadakan.

Standar deviasi residual sebesar 3.055,7578 menunjukkan bahwa penyebaran kesalahan prediksi masih cukup besar.

Hasil analisis residual tersebut memperkuat temuan bahwa model Regresi Linear masih mempunyai keterbatasan dalam memprediksi saldo nasabah, terutama pada nilai saldo ekstrem.

3.6 Rekapitulasi Hasil Praktikum

3.6.1 Rekap Hasil Evaluasi Kedua Algoritma — Cell 23

Tahap terakhir dalam praktikum adalah menyusun rekapitulasi hasil evaluasi kedua algoritma menggunakan DataFrame pandas.

Rekapitulasi dibuat untuk memperlihatkan algoritma yang digunakan, variabel target, metrik evaluasi, dan hasil utama dari masing-masing model.

Hasil rekapitulasi:

	Algoritma	Target	Metrik Evaluasi	Hasil Utama
0	Gaussian Naive Bayes	Berlangganan Deposito (y)	Accuracy, Precision, Recall, F1	Accuracy: 0.8452; F1: 0.4123
1	Regresi Linear	Saldo Rekening (balance)	MAE, MSE, RMSE, R2	RMSE: 3055.7632; R2: 0.0469

Berdasarkan hasil rekapitulasi, kedua algoritma telah berhasil dijalankan menggunakan dataset Bank Customers.

Gaussian Naive Bayes digunakan untuk menyelesaikan masalah klasifikasi dengan target keputusan berlangganan deposito. Model menghasilkan accuracy sebesar 84,52% dan F1-score kelas positif sebesar 41,23%.

Sementara itu, Regresi Linear digunakan untuk menyelesaikan masalah prediksi numerik dengan target saldo rekening. Model menghasilkan RMSE sebesar 3.055,7632 dan R^2 sebesar 0,0469.

Kedua hasil tersebut tidak dapat dibandingkan secara langsung untuk menentukan algoritma yang lebih baik karena masing-masing digunakan untuk target dan jenis permasalahan yang berbeda.

Hasil praktikum menunjukkan bahwa proses preprocessing, pelatihan, dan evaluasi model telah berhasil dijalankan. Meskipun demikian, kedua model masih memiliki keterbatasan berdasarkan hasil pengujian masing-masing.

Pada Gaussian Naive Bayes, keterbatasan utama terdapat pada kemampuan mengenali kelas positif. Sementara itu, pada Regresi Linear, keterbatasan utama terlihat dari rendahnya kemampuan model menjelaskan variasi saldo rekening.

Dengan demikian, hasil praktikum menegaskan bahwa keberhasilan pemodelan perlu dinilai tidak hanya berdasarkan apakah kode berhasil dijalankan, tetapi juga berdasarkan kesesuaian algoritma dengan target, karakteristik dataset, dan nilai evaluasi yang diperoleh.

BAB IV

PENUTUP

Berdasarkan pelaksanaan praktikum UTS Pembelajaran Mesin menggunakan dataset Bank Customers, dapat disimpulkan bahwa seluruh tahapan utama pengolahan data dan pemodelan telah berhasil dilaksanakan menggunakan Python pada Jupyter Notebook.

Dataset yang digunakan terdiri atas 45.211 observasi dengan 17 variabel yang mencakup karakteristik nasabah, informasi keuangan, dan riwayat pemasaran bank. Berdasarkan hasil Exploratory Data Analysis (EDA), tidak ditemukan missing values maupun baris duplikat. Namun, terdapat kategori unknown pada sejumlah variabel dan nilai ekstrem pada variabel balance.

Hasil analisis juga menunjukkan bahwa distribusi target keputusan berlangganan deposito tidak seimbang. Sebanyak 39.922 nasabah atau 88,30% tidak berlangganan deposito, sedangkan 5.289 nasabah atau 11,70% berlangganan deposito. Kondisi tersebut menjadi pertimbangan penting dalam mengevaluasi algoritma klasifikasi.

Pada algoritma Gaussian Naive Bayes, proses preprocessing, training, prediksi, dan evaluasi berhasil dilaksanakan. Model menghasilkan accuracy sebesar 84,52%, precision kelas positif sebesar 37,08%, recall sebesar 46,41%, dan F1-score sebesar 41,23%. Hasil tersebut menunjukkan bahwa model mampu melakukan klasifikasi, tetapi kemampuannya mengenali nasabah yang benar-benar berlangganan deposito masih terbatas.

Pada algoritma Regresi Linear, model berhasil dilatih untuk memprediksi saldo rekening nasabah. Hasil evaluasi menunjukkan nilai MAE sebesar 1.486,6445, MSE sebesar 9.337.688,8114, RMSE sebesar 3.055,7632, dan R^2 sebesar 0,0469.

Nilai R^2 tersebut menunjukkan bahwa model Regresi Linear hanya mampu menjelaskan sekitar 4,69% variasi saldo pada data testing. Hasil scatter plot dan analisis residual juga menunjukkan adanya kesalahan prediksi yang cukup besar, terutama pada nasabah dengan saldo rekening tinggi.

Dengan demikian, kedua algoritma telah berhasil diterapkan sesuai tujuan masing-masing, yaitu Gaussian Naive Bayes untuk klasifikasi keputusan berlangganan deposito dan Regresi Linear untuk prediksi saldo rekening. Namun, hasil evaluasi menunjukkan bahwa kualitas prediksi kedua model masih memiliki keterbatasan.

Praktikum ini memberikan pemahaman bahwa keberhasilan implementasi algoritma tidak hanya dilihat dari kemampuan program menghasilkan prediksi, tetapi juga dari kualitas hasil pengujian, pemilihan fitur, karakteristik data, serta kesesuaian algoritma dengan permasalahan yang diselesaikan.

DAFTAR PUSTAKA

- *Izma, F., & Firmansyah, H. (2026). Penerapan algoritma Naive Bayes untuk memprediksi keputusan berlangganan deposito berjangka pada kampanye pemasaran langsung. Jurnal Dinamika Informatika, 15(1), 140–148. https://doi.org/10.31316/jdi.v15i1.427*
- *Mujahid, M., Kına, E., Rustam, F., Villar, M. G., Alvarado, E. S., de la Torre Díez, I., & Ashraf, I. (2024). Data oversampling and imbalanced datasets: An investigation of performance for machine learning and feature engineering. Journal of Big Data, 11, Article 87. https://doi.org/10.1186/s40537-024-00943-4*
- *Müller-Plath, G., & Lüdecke, H.-J. (2024). Normalized coefficients of prediction accuracy for comparative forecast verification and modeling. Research in Statistics, 2(1), Article 2317172. https://doi.org/10.1080/27684520.2024.2317172*
- *Vargas, V. W. de, Aranda, J. A. S., Costa, R. dos S., Pereira, P. R. da S., & Barbosa, J. L. V. (2023). Imbalanced data preprocessing techniques for machine learning: A systematic mapping study. Knowledge and Information Systems, 65(1), 31–57. https://doi.org/10.1007/s10115-022-01772-8*
- *Watono, B., Utami, E., & Ariatmanto, D. (2024). Stacking ensemble learning and instance hardness threshold for bank term deposit acceptance classification on imbalanced dataset. Jurnal Teknik Informatika (JUTIF), 5(4). https://doi.org/10.52436/1.jutif.2024.5.4.2022*